Thomas

Der Verordnungs-Check

Weniger Admin, mehr Zeit für Patienten

IHK-Präsentation · Arbeitsstand 23.10.2026

Thomas Kullmann · Valentin Klamka · Derk Ermler

KI-gestützte Prüfung von Heilmittelverordnungen (Physiotherapie, GKV, Muster 13) · Praxis anonymisiert, nur synthetische Testdaten

Ablauf: drei Rollen, ein roter Faden

Thomas

Thomas

ca. 15 min

Koordination, Ist/Soll & Business Case

- Unternehmen und Ist-Situation
- Einsatzfelder im Unternehmen
- Soll, Ziele, Business Case
- Schluss: Reflexion und Fazit

IHK-Punkte: Ist/Soll 10 · Einsatzfelder 10 · Roter Faden 15

Valentin

ca. 15 min

Tools, Architektur & Governance

- Tool-Vergleich: warum, warum nicht
- Architekturentscheidungen
- EU AI Act und DSGVO

IHK-Punkte: Tool-Vergleich 10 · Tool-Auswahl 10

Derk

ca. 15 min

Build, Demo & Evaluation

- Die vier Prüfer
- Live-Demo
- Erfolgsmessung, Testbatterie
- Einsatzplanung und Risiken

IHK-Punkte: Einsatzplanung 10 · Erfolgsmessung 10

Gesamt ca. 45 min · Orthografie und Schreibstil (25 Punkte) verantworten wir gemeinsam im Vier-Augen-Prinzip

Das Unternehmen: Physiotherapie im GKV-System

Thomas

ca. 10

Mitarbeitende, zwei Standorte

ca. 40

neue Kassenverordnungen pro Woche

3–6 %

vom Umsatz an den externen Abrechnungsdienstleister

keine

KI im Prüfprozess; die Praxissoftware verwaltet, prüft aber nicht

Warum die Verordnung so wichtig ist

- Jede Behandlung zu Lasten der Krankenkasse braucht eine gültige ärztliche Verordnung (Muster 13).
- Ob sie gültig ist, regeln öffentliche Regelwerke: Heilmittel-Richtlinie und Heilmittelkatalog des G-BA, Diagnoseliste der KBV.
- Ist die Verordnung fehlerhaft, behandelt die Praxis auf eigenes Risiko: Die Kasse kann die Vergütung kürzen (Absetzung).

Quelle: Field Study, Ist-Interview mit der Mitinhaberin (anonym) am 16.10.2026

Ist-Situation: So prüft die Praxis heute

Thomas

Annahme
Rezeption prüft die Verordnung
Ø 6 min

Behandlung
Leistung wird erbracht

Schlussprüfung
vor der Abrechnung
ca. 2 min

Dienstleister
rechnet ab
3–6 % vom Umsatz

Krankenkasse
kürzt bei Fehlern
ca. 10 Fälle/Jahr

90 %
der Fehler entstehen bei Doppel- und Folgeverordnungen

≤ 85 %
Wirksamkeit menschlicher Doppelkontrollen

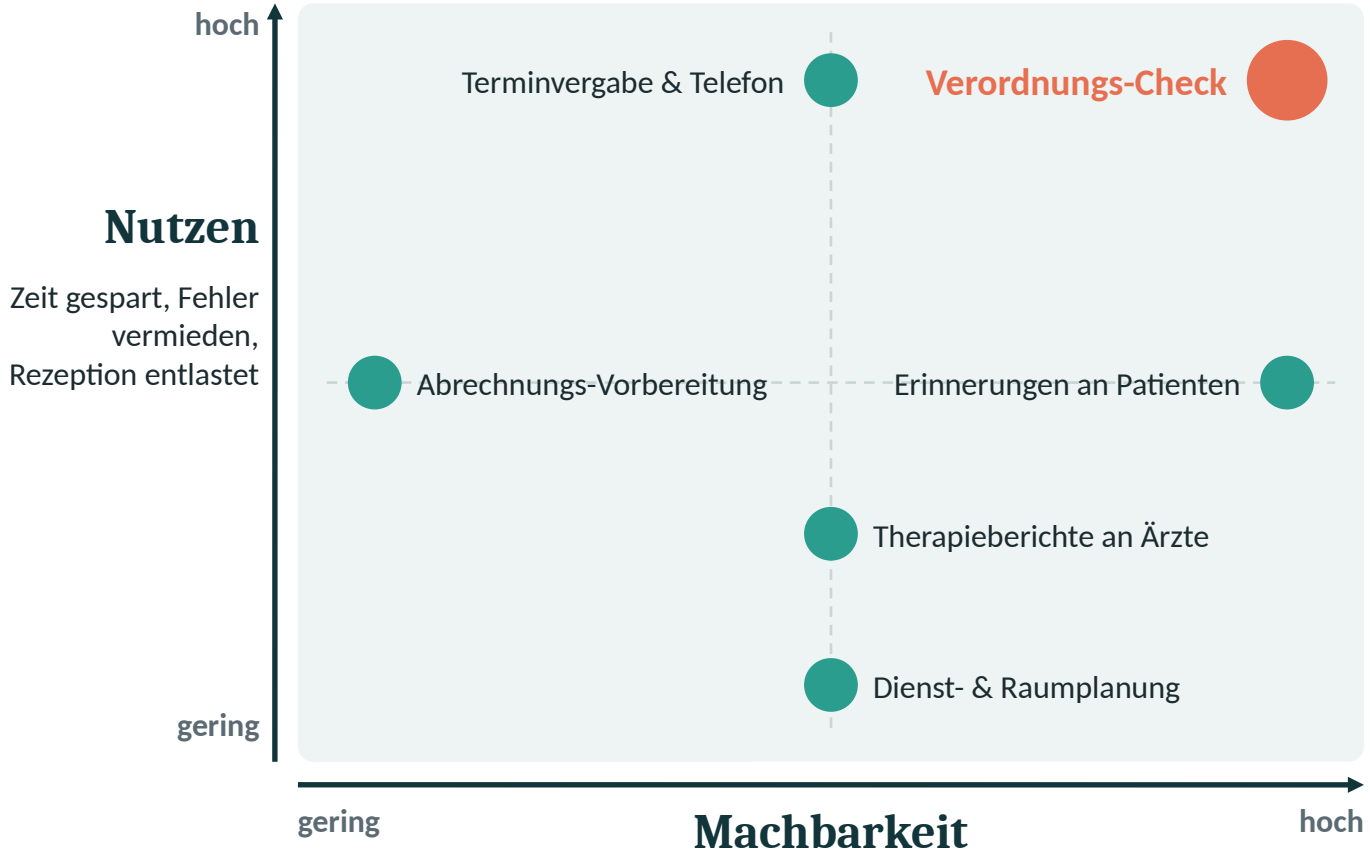
5,3 h
Prüfzeit pro Woche: 40 Verordnungen × 8 min

Quelle: Field Study, Ist-Interview am 16.10.2026 · Die Praxissoftware zeigt nicht, wie viele Einheiten ein Patient beim selben Arzt schon hatte

Einsatzfelder: erst die Landkarte, dann der Pilot

Thomas

ENTWURF



Daten vorhanden, ohne Schnittstelle zur Praxissoftware umsetzbar, geringes Risiko (Datenschutz, Fehlentscheidung)

Warum dieser Pilot

- Trifft das größte Problem: 90 % der Fehler
- Regeln sind öffentlich und belegbar (G-BA, KBV)
- Keine Schnittstelle nötig: Eingabe per Chat oder Formular
- Geringes Risiko: Die Rezeption entscheidet
- Messbar: Zeit, Trefferquote, Nacharbeit

Einschätzung des Teams, keine Messung · im Pilot nur für den Verordnungs-Check überprüft

Soll: Fehler vor der Behandlung finden

Thomas

Soll-Prozess

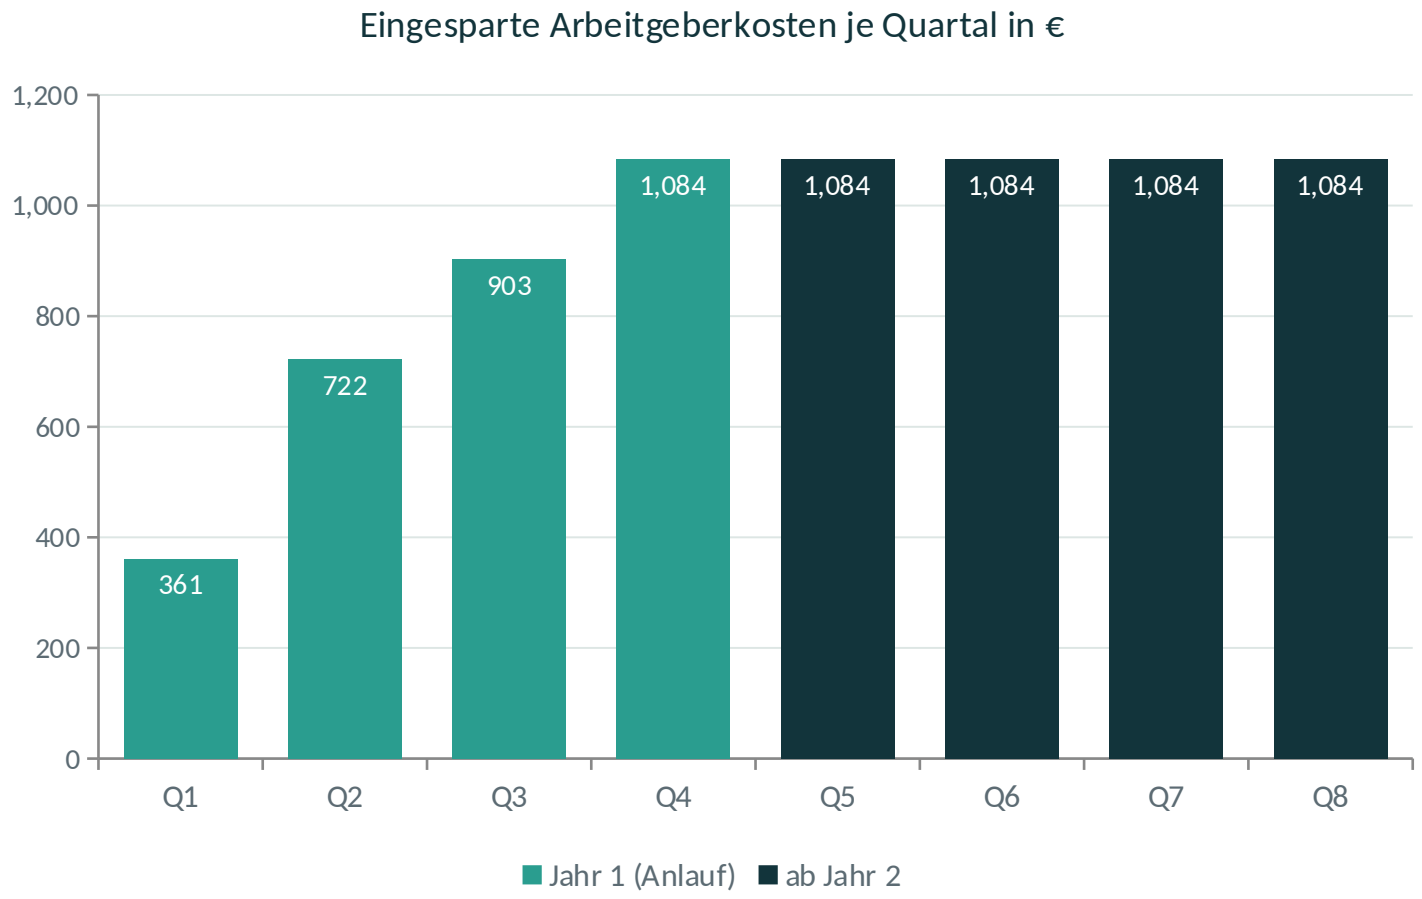
1. **Verordnung kommt an**
   Rezeption gibt sie per Formular oder Chat ein
2. **KI prüft in ca. 30 s**
   vier Prüfer, Ampel mit Fundstelle im Regelwerk
3. **Rezeption entscheidet**
   behandeln, nachfragen oder korrigieren lassen
4. **Schlussprüfung entfällt schrittweise**
   erst nach bestandenem Parallelbetrieb

Ziel	Erfolgsindikator	Messung
Zeit	Prüfzeit −50 % nach 2 Quartalen, −75 % nach 4	Stoppuhr-Stichprobe vorher/nachher
Qualität	≥ 98 % richtige Ampel, 0 übersehene rote Fälle	Evaluation mit ≥ 50 Fällen × 3 Läufe
Vertrauen	≤ 1 kritischer Fehlalarm	Abweichungen im Parallelbetrieb
Akzeptanz	Rezeption folgt der Ampel	Quote im Pilot, Rückmeldungen

Die Indikatoren sind zugleich der Kontrollmaßstab in der Erfolgsmessung (Derk).

Business Case: 75 % weniger Prüfzeit nach einem Jahr

Thomas



Jahr 1

≈ 3.070 €

146 h frei · Anlauf 25 → 75 %

ab Jahr 2

≈ 4.300 € / Jahr

207 h frei · etwa ½ Minijob

Der Hebel ist die Prüfzeit, nicht die Absetzungen (nur ca. 500 € pro Jahr). Ziel: einen zusätzlichen Minijob bei Wachstum vermeiden, keine Stelle ersetzen.

5,3 h/Woche × 13 Wochen je Quartal · Anstieg Q1 25 % · Q2 50 % · Q3 62,5 % · Q4 75 %, danach 75 % · 20,97 € je Stunde (Herleitung nächste Folie)

Annahmen und Einordnung des Business Case

Thomas

Größe	Wert	Herkunft
Prüfzeit heute	5,3 h pro Woche (40 × 8 min)	Ist-Interview 16.10.2026
Einsparziel	50 % nach 2 Quartalen, 75 % nach 4	Annahme des Teams
Stundenlohn	15,99 € = Mindestlohn 2026 (13,90 €) + 15 %	Annahme; Marktvergleich Rezeption 12,77–15,36 €/h (gehalt.de)
Arbeitgeberkosten	20,97 €/h mit Minijob-Pauschalabgaben (bis 31,17 %)	Minijob-Regeln
Minijob	max. 603 €/Monat ≈ 8,7 h/Woche; ≈ 9.500 €/Jahr mit Abgaben	Minijob-Grenze 2026

Einordnung

- Nicht doppelt gezählt: Die freien Stunden sind der halbe Minijob, nicht zusätzlich.
- „Vermeiden“ statt „ersetzen“: keine Kündigung, sondern keine zusätzliche Stelle bei Wachstum.
- Ab 2027 Mindestlohn 14,60 € – Ersparnis steigt leicht.
- Gegenzurechnen: KI-Kosten 70–142 €/Jahr (Valentin), dazu n8n- und Supabase-Abo.

Annahmen sind gekennzeichnet · alle Rechenwege in der Projektarbeit, Kapitel 1

Tool-Vergleich: von den Anforderungen zur Auswahl

Valentin

1 · Anforderungen
aus Ist/Soll abgeleitet

2 · Kriterien
fünf IHK-Kriterien

3 · Vorauswahl
je Baustein 2–4 Kandidaten

4 · Praxistest
Prototyp v1 bis Merge

5 · Fazit
begründete Auswahl

Anforderung aus dem Ist/Soll	IHK-Kriterium
Verordnungen sind Gesundheitsdaten (Art. 9 DSGVO); Daten in der EU, Pseudonym statt Name	Datenschutz
Rezeption ohne IT-Kenntnisse: Formular oder Chat, Antwort in Sekunden	Benutzerfreundlichkeit
Jeder Befund mit Fundstelle aus öffentlichen Regelwerken; Regeln ändern sich jährlich	Funktionalität
Keine Schnittstelle zur Praxissoftware nötig, Protokoll jeder Prüfung	Integrationsfähigkeit
Laufende Kosten klein gegenüber der eingesparten Zeit (Ziel ≤ 5 Cent je Prüfung)	Kosten

Orchestrierung: n8n und die Alternativen

Valentin

Kandidat	Stärke	Schwäche für unseren Fall	Ergebnis
n8n	Agenten, Vektorsuche und Code-Knoten in einem Workflow; native Knoten für OpenAI und Supabase; Export als JSON für GitHub	Kein fertiges Frontend; JavaScript-Kenntnisse für Code-Knoten nötig	gewählt
Microsoft Copilot Studio	Im MSIT-Programm bekannt, gute Chat-Oberfläche	Anbindung an Supabase und eigene Rechenlogik umständlicher; n8n ist Kernplattform des Capstones	verworfen
Eigener Code (z. B. Python)	Volle Kontrolle	Mehr Bauzeit; schwerer für die Praxis zu warten	verworfen
Eigenes Frontend (z. B. Lovable)	Schöne Oberfläche	Kostet Bauzeit ohne Prüfnutzen; n8n-Formular und -Chat reichen	verworfen
Reine Regel-Engine ohne KI	Deterministisch	Eingabe ist Freitext, Regeln stehen in langen PDF-Regelwerken – dafür braucht es Sprachverständnis	verworfen

Ehrlich bleiben: n8n ist durch das MSIT-Capstone vorgegeben – wir haben es trotzdem gegen die Alternativen bewertet · Quelle: docs/implementierung.md

Sprachmodell und Embeddings: klein, günstig, einheitlich

Valentin

Kandidat	Warum (nicht)	Ergebnis
gpt-4.1-mini, Temperatur 0,1	Reicht, weil Regeln der Code rechnet; ca. 3–4 Cent und ca. 25 s je Prüfung; niedrige Temperatur = reproduzierbarer	gewählt
Größere Modelle	Mehr Kosten und Wartezeit; der wichtigste Fehler (falsche ICD-Zuordnung) wurde nicht durch Modellgröße, sondern durch Code gelöst	verworfen
Modell mit EU-Hosting	Datenschutz-Vorteil; im Prototyp nur synthetische Daten → vor Echtbetrieb neu bewerten (OpenAI bietet seit Feb. 2025 EU-Datenresidenz für API-Projekte)	Echtbetrieb
text-embedding-3-small	Wissensbasis (380 Abschnitte, 1.536 Dimensionen) ist damit geladen – Suchanfragen müssen mit demselben Modell eingebettet werden	gewählt
Gemini über OpenRouter	Embeddings eines anderen Modells liegen in einem anderen Vektorraum → Suche wertlos. Nur nach komplettem Neuladen der Wissensbasis möglich	verworfen

Kosten je Prüfung: Schätzung aus ca. 77.000 Eingabetoken, noch keine gemessene Abrechnung

Beim Zusammenführen gelernt

Embedding-Modell: zwingend dasselbe wie beim Laden der Wissensbasis.

Chat-Modell: bewusst vereinheitlicht, damit alle Testergebnisse vergleichbar bleiben. Technisch wäre ein anderes möglich.

Wissensbasis: warum RAG mit Supabase pgvector

Valentin

Ansatz	Warum (nicht)	Ergebnis
RAG: Regelwerke als Abschnitte in einer Vektorsuche	Jeder Befund kann seine Fundstelle nennen; neue Fassung = Knopfdruck „Wissensbasis laden“ (KBV-Liste z. B. jährlich zum 1. Januar)	**gewählt**
Fine-Tuning des Modells	Regeln ändern sich jährlich → jedes Mal neu trainieren; keine überprüfbare Fundstelle; teuer	verworfen
Gesamte Regelwerke in den Prompt	Hunderte Seiten je Prüfung → hohe Kosten und lange Wartezeit	verworfen
Supabase pgvector (EU, Frankfurt)	Eine Datenbank für Wissensbasis, Protokoll und künftig Historie; Zugriffsschutz auf Zeilenebene; EU-Region	**gewählt**
Eigenständige Vektordatenbank	Zweites System mit eigenem Vertrag und Zugang – ohne Mehrwert bei ca. 380 Abschnitten	verworfen

Nur frei zugängliche Quellen

- Heilmittel-Richtlinie (G-BA): 236 Abschnitte
- Heilmittelkatalog (G-BA): 82
- KBV-Diagnoseliste: 62
- ICD-10-GM bewusst nicht vollständig im Repository (Nutzungsvertrag BfArM)

Grenze erkannt (23.10.): Tabellen aus PDF liest das Modell unzuverlässig → KBV-Liste künftig als Tabelle im Code (Entscheidung offen)

Eingabekanal und Gesamtkosten (TCO)

Valentin

ENTWURF

Kanal	Stand	Bewertung
Formular (Muster 13)	umgesetzt	Strukturiert, kein Extraktionsfehler, Patientendaten werden vor dem Modell ersetzt
Chat (Text oder JSON)	umgesetzt	Schnell für Rückfragen; Freitext braucht Extraktion
Foto + Vision-KI	nur bei Puffer	Bequem, aber Lesefehler; Brücke bis zur E-Verordnung
Scan + OCR, E-Mail, Messenger	verworfen	Mehr Schritte oder unsicherer Kanal für Gesundheitsdaten
Praxissoftware / E-Verordnung	Ausblick	Beste Lösung, aber Schnittstelle nötig; E-Verordnung über die TI macht Texterkennung zur Übergangslösung

Ergebnis TCO-Vergleich

KI-Kosten

70–142 € / Jahr

Gesamtkosten je Kanal

823–2.054 € / Jahr

Die Eingabezeit der Rezeption bestimmt die Kosten, nicht die KI.

TCO-Entwurf vom 19.10.2026 · offen: Gewichtung der Kriterien, Preisquellen mit Abrufdatum

Architektur: Regeln rechnet der Code, Sprache das Modell

Valentin

Eingang

Formular oder Chat

Erfassen

Schema, Patientendaten entfernen

Fakten

Fristen, Formate, ICD → Gruppe, Leitsymptomatik, Summen

4 Prüfer

Formal · Diagnose · Mengen · Fristen

Ampel

grün / gelb / rot, Protokoll

Dunkel = Code (deterministisch, getestet) · hell = Sprachmodell

Stack

- n8n Cloud: Workflow, Formular, Chat
- OpenAI gpt-4.1-mini, text-embedding-3-small
- Supabase (Frankfurt): Wissensbasis, Protokoll
- GitHub: Exporte, Tests, Doku

Leitsatz aus der Evaluation

Was sich als Regel aufschreiben lässt, rechnet der Code. Das Sprachmodell nur dort, wo Sprachverständnis nötig ist: Freitext erfassen, Regelwerk durchsuchen, Befunde formulieren.

Architekturentscheidung 1: Code oder Sprachmodell?

Valentin

Aufgabe	Wer	Warum nicht das Modell? (Beleg)
Fristen (28 / 14 Tage, Unterbrechung 14 Tage)	Code	Datumsrechnen ist keine Sprachaufgabe; in v1–v3 rechnete das Modell Tage falsch
LANR / BSNR (9 Ziffern)	Code	v1: Modell „prüfte“ Prüfziffern im Kopf → 4 von 7 Fällen falsche Fehler
ICD-Code → Diagnosegruppe (WS / EX)	Code	v3: Modell ordnete einen Knie-Code der Wirbelsäule zu – mit plausibler Begründung
Leitsymptomatik je Diagnosegruppe	Code	23.10.: Modell behauptete „a gibt es bei WS nicht“ → kritischer Fehlalarm
Summen, Ampel, Absetzungsrisiko	Code	Muss nachvollziehbar und prüfbar sein
Freitext erfassen, Regelwerk finden, Befund formulieren	Modell	Braucht Sprachverständnis – hier ist das Modell stark

Ergebnis: kritische Fehlalarme von 12 (v1) auf 0 (v4); Code-Regeln mit 34 automatischen Tests (v4 und Merge) abgesichert

Quellen: docs/evaluation.md, docs/aenderungsprotokoll.md, tests/fakten.test.mjs

Architekturentscheidung 2: Aufbau, Sicherheit, Betrieb

Valentin

Entscheidung	Statt	Warum
Vier spezialisierte Prüfer	Ein Allround-Agent	Jedes Mandat einzeln testbar; Fehler lassen sich einem Prüfer zuordnen
Patientendaten vor dem Modell ersetzen	Rohdaten an das Modell	Datenminimierung: Die Prüfung braucht keine Namen; Original bleibt nur im Protokoll
Mensch entscheidet, Ampel ist Empfehlung	Automatische Abweisung	Verantwortung bleibt bei der Praxis; menschliche Aufsicht
Fristen-Prüfer ohne Vektorsuche	Suche wie die anderen Prüfer	Die Regel (HeilM-RL § 15, § 16) ist kurz und fest – Suche bringt nur Rauschen
Formular im selben Workflow	Formular ruft Chat-Webhook auf	Ein Ablauf, ein Protokoll, keine zweite öffentliche Adresse
Zwei Workflows: Merge + v4 als Fallback	Nur ein Stand	Vor der Prüfung immer eine lauffähige Rückfallversion
Veröffentlichung erst mit Anmeldung	Offener Chat-Link	Sonst kann jeder mit dem Link Kosten erzeugen

Quellen: docs/architektur.md (Trade-offs), docs/implementierung.md (erwogen und verworfen), n8n/README.md

EU AI Act: warum kein Hochrisiko-System

Valentin

1	**KI-System?** Art. 3 Nr. 1	Ja	Ja: Das Modell leitet aus Eingaben Befunde ab. Wir (Team) sind Anbieter (Art. 3 Nr. 3), die Praxis ist Betreiberin (Art. 3 Nr. 4).
2	**Verbotene Praxis?** Art. 5	Nein	Nein: keine Manipulation, keine Bewertung von Personen, keine Biometrie oder Emotionserkennung.
3	**Hochrisiko: Produkt?** Art. 6 Abs. 1 + Anhang I (MDR)	Nein	Nein: kein Medizinprodukt. Zweck ist eine formale, administrative Prüfung für die Abrechnung – keine Diagnose oder Therapieentscheidung (Art. 2 Nr. 1 MDR; MDCG 2019-11).
4	**Hochrisiko: Anhang III?** Art. 6 Abs. 2	Nein	Nein: Nr. 5 a erfasst Behörden (oder Handeln in deren Namen), die über Ansprüche auf öffentliche Leistungen entscheiden. Wir sind eine private Praxis, prüfen ein Dokument – über die Leistung entscheidet die Kasse. Nr. 5 c (Versicherungstarife) und Nr. 4 (Beschäftigte) ebenfalls nicht.

Ergebnis: kein Hochrisiko-KI-System. Die Ausnahme nach Art. 6 Abs. 3 (mit Dokumentations- und Registrierungspflicht) brauchen wir nicht, weil kein Anhang-III-Fall vorliegt.

EU AI Act: Was für uns trotzdem gilt

Valentin

Pflicht	Seit	Unsere Umsetzung
Art. 4 KI-Kompetenz: Anbieter und Betreiber ergreifen Maßnahmen, um die KI-Kompetenz ihres Personals zu fördern	02.02.2025; seit 27.07.2026 als Förderpflicht (KI-Omnibus)	Einweisung von Inhaberin und Rezeption vor dem Parallelbetrieb, dokumentiert: Was kann das System, wo irrt es, wer entscheidet
Art. 50 Abs. 1 Transparenz: Nutzer erfahren, dass sie mit einer KI interagieren (entfällt, wenn offensichtlich)	02.08.2026	Formular und Antwort sind als KI-Prüfung gekennzeichnet; Ampel als „Empfehlung, keine Entscheidung“
Pflichten für Hochrisiko-Betreiber (Art. 26)	entfällt	Trotzdem freiwillig übernommen (Art. 95): menschliche Aufsicht, Protokoll jeder Prüfung, Fundstelle je Befund
Pflichten für KI-Modelle mit allgemeinem Verwendungszweck (Art. 53 ff.)	trifft OpenAI	Nicht unsere Pflicht als Anbieter des Gesamtsystems; Modellwahl dokumentiert

Zu prüfen vor Echtbetrieb: Art. 50 Abs. 2 (maschinenlesbare Kennzeichnung erzeugter Inhalte) zielt auf Generatoren synthetischer Inhalte – ob er interne Prüfbefunde erfasst, klären wir.

KI-Verordnung (EU) 2024/1689, geändert durch VO (EU) 2026/1744 (KI-Omnibus, in Kraft seit 27.07.2026) · Quellen im Anhang

DSGVO und Berufsgeheimnis

Valentin

Thema	Norm	Umsetzung
Gesundheitsdaten	Art. 4 Nr. 15, Art. 9 Abs. 1 DSGVO	Verordnungen sind besonders geschützt; Prototyp nur mit synthetischen Daten
Rechtsgrundlage (Echtbetrieb)	Art. 9 Abs. 2 lit. h, Abs. 3 DSGVO i. V. m. § 22 Abs. 1 Nr. 1 lit. b BDSG	Verarbeitung zur Verwaltung im Gesundheitsbereich durch Personal mit Schweigepflicht
Datenminimierung, Datenschutz durch Technik	Art. 5 Abs. 1 lit. c, Art. 25	Patientendaten vor dem Modell ersetzt, Pseudonym statt Name
Dienstleister	Art. 28; § 203 Abs. 3, 4 StGB	Auftragsverarbeitung mit n8n, OpenAI, Supabase; Verpflichtung zur Verschwiegenheit
Drittland	Art. 44 ff.	Supabase in Frankfurt; für OpenAI EU-Datenresidenz oder Data Privacy Framework prüfen
Sicherheit	Art. 32	Zugriffsschutz auf Zeilenebene, Schlüssel nie im Repository, Anmeldung
Keine automatisierte Entscheidung	Art. 22	Die Rezeption entscheidet über jede Verordnung
Folgenabschätzung	Art. 35, Erwägungsgrund 91	Vor Echtbetrieb prüfen und dokumentieren (neue Technologie + Gesundheitsdaten)

Physiotherapeutinnen sind Berufsgeheimnisträgerinnen (§ 203 Abs. 1 Nr. 1 StGB) – Dienstleister sind „mitwirkende Personen“: sorgfältig auswählen, zur Verschwiegenheit verpflichten, nur Erforderliches offenbaren

Bauplan: Alle vier Prüfer sind gleich aufgebaut

Derk

Eingabe

Verordnung im festen Schema (Patientendaten ersetzt) + berechnete Fakten aus dem Code (verbindlich)

Prüf-Agent

gpt-4.1-mini, Temperatur 0,1, max. 6 Schritte, eigenes Mandat im Systemprompt

Ausgabe

JSON: Prüfer, Befund je Feld mit Status, Fundstelle, Korrekturhinweis

Werkzeug „Regelwerk“

Vektorsuche in Supabase, 5 Treffer, je Prüfer eigener Ausschnitt der Wissensbasis. Der Fristen-Prüfer braucht keine Suche – seine Regel steht fest.

Gemeinsame Regeln für alle Prüfer

- Nur das eigene Mandat prüfen
- Keine Paragrafen erfinden – jede Regel mit Fundstelle
- Keine Fundstelle gefunden: höchstens „Hinweis“
- Berechnete Fakten haben Vorrang vor eigener Einschätzung

Die vier Prüfer: wer prüft was

Derk

Prüfer	Mandat	Fakten aus dem Code	Beispiel aus dem Test
Formal	Vollständigkeit der Pflichtangaben (10 Felder, HeilM-RL § 13)	Pflichtangaben ja/nein, LANR/BSNR-Format	LANR und Leitsymptomatik fehlen → rot
Diagnose	ICD-Code ↔ Diagnosegruppe, Leitsymptomatik, besonderer Verordnungsbedarf (KBV-Liste)	Passende Gruppe zum ICD-Code, Leitsymptomatik zulässig	Schulter-Code mit Wirbelsäulen-Gruppe → rot
Mengen	Höchstmenge je Verordnung, max. 3 vorrangige Heilmittel, Frequenz	Summe vorrangiger Einheiten, Anzahl Heilmittel	10 Einheiten bei Wirbelsäule → rot
Fristen	Behandlungsbeginn, Unterbrechung (HeilM-RL § 15, § 16)	Tage bis Beginn, Grenze 28/14, Unterbrechung	Beginn nach 41 Tagen → rot

Sprint 2 – Verordnungsfall-Prüfung: Der Mengen-Prüfer bekommt die Summe aller Einheiten im Verordnungsfall (§ 7 HeilM-RL) als Fakt. Das deckt die Folgeverordnungen ab – 90 % der Fehler.

Live-Demo: eine Verordnung in 30 Sekunden prüfen

Derk

1 · Formular

Muster 13 ausfüllen (synthetische Daten)

2 · Prüfen

vier Prüfer laufen parallel, ca. 25–30 s

3 · Ergebnis

Ampel, Korrekturhinweis, Fundstelle

4 · Protokoll

Prüfung und Befunde in Supabase

Demo-Fälle

- Grün: Gonarthrose, EX, 6× KG, fristgerecht
- Rot: Schulter-Code mit Wirbelsäulen-Gruppe
- Rückfall: Screenshots je Ampelfarbe, falls die Verbindung ausfällt

Prototyp: Stand 23.10.2026

Derk

Zwei Workflows

Merge-Workflow (Hauptstand)
Formular und Chat, Patientendaten ersetzen, vier Prüfer, Fakten aus dem Code

Vier Prüfer v4 (Fallback)
unverändert, lauffähig

Noch nicht öffentlich: erst mit aktiver Anmeldung

Datum	Was	Ergebnis
20.10.	Merge gebaut; Testfall 3 als Freitext	rot korrekt, aber Fehlalarm Mengen-Prüfer → Prompt geschärft → behoben
20.10.	Frequenz 4×/Woche	kein Hinweis mehr (HeilM-RL § 12 Abs. 1: Abweichung zulässig)
23.10.	Diagnose-Prüfer geschärft, Leitsymptomatik und Summe in den Code	20 Läufe: 13 einwandfrei; Fehlalarme behoben, 1 Abbruch (Schema)
23.10.	Hinweis besonderer Verordnungsbedarf	**noch unzuverlässig (4 von 4 Läufen verpasst) → KBV-Liste in den Code**

Synthetische Testfälle · Details: docs/aenderungsprotokoll.md · Laufzeit 20–34 s je Prüfung

Erfolgsmessung: ≥ 98 % auf mindestens 50 neuen Fällen

Derk

ENTWURF

Zielwert

≥ 98 %

richtige Ampel, höchstens 1 Fehler bei 50 Fällen, jeder Fall 3 Läufe

Bedingt bereit: 95–98 % · nicht bereit: < 95 %

Kriterium	Ziel	Warum
Übersehene rote Verordnungen	0	Ein übersehener Fehler kostet Geld
Kritische Fehlalarme	≤ 1	Sonst ignoriert die Rezeption die Ampel
Verordnungsfall-Summe	100 % exakt	Wird im Code gerechnet
Fundstelle je Befund	100 %	Nachvollziehbarkeit
Stabilität über 3 Läufe	≥ 95 %	Sprachmodelle schwanken
Laufzeit / Kosten	≤ 30 s / ≤ 5 Cent	Alltagstauglich, wirtschaftlich

Zielwert 98 % nach Rückmeldung der Instruktorin am 19.10.2026 (vorher 90 % auf 12 Fällen) · Referenzstandard: ausschließlich die Regelwerke

Testbatterie: 100 synthetische Fälle, sauber getrennt

Derk

ENTWURF

Evaluation (Holdout)

65

nie zum Nachbessern verwendet

Entwicklung

35

darf zum Nachbessern genutzt werden

Evaluationsset (65 Fälle)

20	10	35	8
grün Vorgabe ≥ 12	gelb Vorgabe ≥ 8	rot Vorgabe ≥ 25	Grenzfall Vorgabe ≥ 5

Rote Fälle je Prüfer ≥ 5: Formal 10, Diagnose 10, Mengen 9, Fristen 10

Regel	Warum
Soll-Werte aus den Regelwerken abgeleitet, Vier-Augen-Prüfung im Team	Referenzstandard sind nur die Regelwerke
Keine ICD-Codes aus Testfällen in Prompts	Kein Lernen auf den Test
Festes Prüfdatum 26.10.2026	Fristen bei jedem Lauf gleich
65 × 3 = 195 Prüfungen, ca. 1,5 h und 6–8 €	Stabilität statt Einzelergebnis

Bisher (v4, 10 Fälle): 10/10 Ampeln korrekt, kritische Fehlalarme 12 → 0 – zählt nicht als formale Evaluation · tests/testbatterie.md

Einsatzplanung: vom Parallelbetrieb zum Regelbetrieb

Derk

ENTWURF

0 · Vorbereitung

2 Wochen

- Anmeldung aktiv
- Auftragsverarbeitung, Verschwiegenheit
- Einweisung (KI-Kompetenz, Art. 4)

Weiter, wenn:

Datenschutz freigegeben

1 · Parallelbetrieb

6 Wochen

- Rezeption prüft wie bisher
- System läuft mit
- Abweichungen werden protokolliert

Weiter, wenn:

≥ 98 % Übereinstimmung, 0 übersehene rote

2 · Unterstützt

bis Ende Q2

- System prüft zuerst
- Mensch bestätigt die Ampel
- Schlussprüfung bleibt

Weiter, wenn:

Prüfzeit −50 %

3 · Regelbetrieb

ab Q3

- Doppelabrechnungs-Prüfung
- Foto-Upload der Verordnung
- Monatlicher Qualitätsbericht

Weiter, wenn:

Prüfzeit −75 %

Verantwortlich in der Praxis: Inhaberin · Parallelbetrieb von der Praxis zugesagt (Field Study) · Rückfallebene: Prüfung wie heute, ohne System

Phasen entsprechen dem Einsparziel 50 % / 75 % · Dauer der Phasen noch mit der Praxis abzustimmen

Risiken und nächste Schritte

Derk

ENTWURF

Risiko	Gegenmaßnahme
Modell irrt, klingt aber plausibel	Regeln im Code, Fundstelle Pflicht, Mensch entscheidet
Tabellen aus PDF werden falsch gelesen (KBV-Liste)	KBV-Einträge für WS/EX als Tabelle im Code
Historie unvollständig	Einmaliger Import laufender Fälle; Fallprüfung nur als Hinweis
Regelwerk ändert sich	Wissensbasis neu laden (KBV-Liste jährlich), Stand anzeigen
Modellantwort passt nicht ins Schema	Automatische Wiederholung („Retry on Fail“)
Akzeptanz an der Rezeption	Parallelbetrieb, Einweisung, wenige Fehlalarme

Nächste Schritte

Sprint 2	Verordnungsfall-Prüfung (v5)
26.–30.10.	Evaluation mit 65 Fällen × 3
02.11.	Generalprobe 3 × 15 min
03.11.	MSIT-Prüfung
05.11.	IHK-Prüfung

Reflexion: Was wir gelernt haben

Thomas

ENTWURF

Fehler finden war leicht, Fehlalarme senken war die Arbeit

Baseline: alle 8 Fehler erkannt, aber 12 kritische Fehlalarme

Regeln gehören in den Code

Bestätigt bis zuletzt: ICD-Zuordnung, Leitsymptomatik, KBV-Liste

Die Field Study hat den Schwerpunkt verschoben

90 % der Fehler bei Folgeverordnungen → Verordnungsfall-Prüfung zuerst

Zusammenführen braucht Kompatibilität

Embedding-Modell und Wissensbasis gehören zusammen; Fallback behalten

Für künftige Projekte

- Erst Field Study, dann bauen
- Früh messen; Testfälle vor dem Tuning trennen
- Rechtliche Einordnung an der Zweckbestimmung festmachen – ändert sie sich, neu prüfen
- Tool-Auswahl regelmäßig überprüfen: E-Verordnung macht Texterkennung zur Übergangslösung

Umfang von Kapitel 6 (Reflexion, roter Faden, Fazit) noch mit dem Tutor zu klären

Fazit: Fehler vor der Behandlung finden

Thomas

≥ 98 %

Zielquote des Systems

gegen höchstens ca. 85 % bei menschlicher Doppelkontrolle

vorher

statt nachher

Fehler fallen vor der Behandlung auf, nicht erst bei der Abrechnung

≈ 4.300 €

pro Jahr ab Jahr 2

etwa ½ Minijob an Prüfzeit frei für Patienten und Telefon

Unsere Empfehlung

Pilot im Parallelbetrieb starten: sechs Wochen mitlaufen lassen, messen, dann entscheiden. Kein Hochrisiko-KI-System, Datenschutz durch Technik eingebaut – die Rezeption behält die Entscheidung und gewinnt Zeit für die Patienten.

Anhang: Rechtsquellen und Stand

Valentin

Quelle	Relevante Stellen	Stand / Hinweis
KI-Verordnung (EU) 2024/1689	Art. 3 Nr. 1, 3, 4 · Art. 4 · Art. 5 · Art. 6 Abs. 1–3 · Anhang I, III · Art. 26 · Art. 50 · Art. 53 · Art. 95	Art. 4 seit 02.02.2025; Art. 50 seit 02.08.2026
VO (EU) 2026/1744 (KI-Omnibus)	Art. 4 als Förderpflicht; Hochrisiko Anhang III ab 02.12.2027, Anhang I ab 02.08.2028	ABl. 24.07.2026, in Kraft seit 27.07.2026
Medizinprodukte-VO (EU) 2017/745	Art. 2 Nr. 1 (Medizinprodukt)	Leitlinie MDCG 2019-11 Rev. 1 zur Software
DSGVO (EU) 2016/679	Art. 4 Nr. 15 · Art. 5 · Art. 9 Abs. 1–3 · Art. 22 · Art. 25 · Art. 28 · Art. 32 · Art. 35 · Art. 44 ff. · EG 26, 91	–
BDSG	§ 22 Abs. 1 Nr. 1 lit. b	–
StGB	§ 203 Abs. 1 Nr. 1, Abs. 3, Abs. 4	Fassung seit 2017 (Mitwirkung Dritter)
Heilmittel-Richtlinie, Heilmittelkatalog (G-BA); Diagnoseliste (KBV)	HeilM-RL § 7, § 12, § 13, § 15, § 16	KBV-Diagnoseliste Stand 01.01.2026

Keine Rechtsberatung · Einordnung durch das Team auf Basis der Normtexte und Sekundärquellen (IHK, Kanzleien), Stand 23.10.2026