Thomas

Der Verordnungs-Check

Weniger Admin, mehr Zeit für Patienten

IHK-Präsentation · Testdeck, Arbeitsstand 20.10.2026

Thomas Kullmann · Valentin Klamka · Derk Ermler

KI-gestützte Prüfung von Heilmittelverordnungen (Physiotherapie, GKV, Muster 13) · Praxis anonymisiert, nur synthetische Testdaten

Ablauf: drei Rollen, ein roter Faden

Thomas

Thomas
ca. 5 min

Koordination, Ist/Soll & Business Case

- Ist-Situation (Field Study)
- Einsatzfelder im Unternehmen
- Soll und Business Case

IHK-Punkte: Ist/Soll 10 · Einsatzfelder 10

Valentin
ca. 5 min

Tools, Architektur & Governance

- Tool-Vergleich
- Tool-Auswahl und Architektur
- Governance: EU AI Act, DSGVO

IHK-Punkte: Tool-Vergleich 10 · Tool-Auswahl 10

Derk
ca. 5 min

Build, Demo & Evaluation

- Prototyp: Stand und Tests
- Erfolgsmessung
- Einsatzplanung und Pilot

IHK-Punkte: Einsatzplanung 10 · Erfolgsmessung 10

Thomas · Schluss
ca. 2 min

Schluss

- Reflexion und Lernpunkte
- Fazit und Empfehlung

IHK-Punkte: Roter Faden 15

Gesamt ca. 17 min · Orthografie und Schreibstil (25 Punkte) verantworten wir gemeinsam im Vier-Augen-Prinzip

Ist-Situation: So prüft die Praxis heute

Thomas

Annahme
Rezeption prüft die Verordnung
Ø 6 min

Behandlung
Leistung wird erbracht

Schlussprüfung
vor der Abrechnung
ca. 2 min

Dienstleister
rechnet ab
3–6 % vom Umsatz

Krankenkasse
kürzt bei Fehlern
ca. 10 Fälle/Jahr

90 %

der Fehler entstehen bei Doppel- und Folgeverordnungen

≤ 85 %

Wirksamkeit menschlicher Doppelkontrollen

5,3 h

Prüfzeit pro Woche: 40 Verordnungen × 8 min

Quelle: Field Study, Ist-Interview mit der Mitinhaberin (anonym) am 16.10.2026 · Die Praxissoftware zeigt nicht, wie viele Einheiten ein Patient beim selben Arzt schon hatte

Einsatzfelder: erst die Landkarte, dann der Pilot

Thomas

ENTWURF



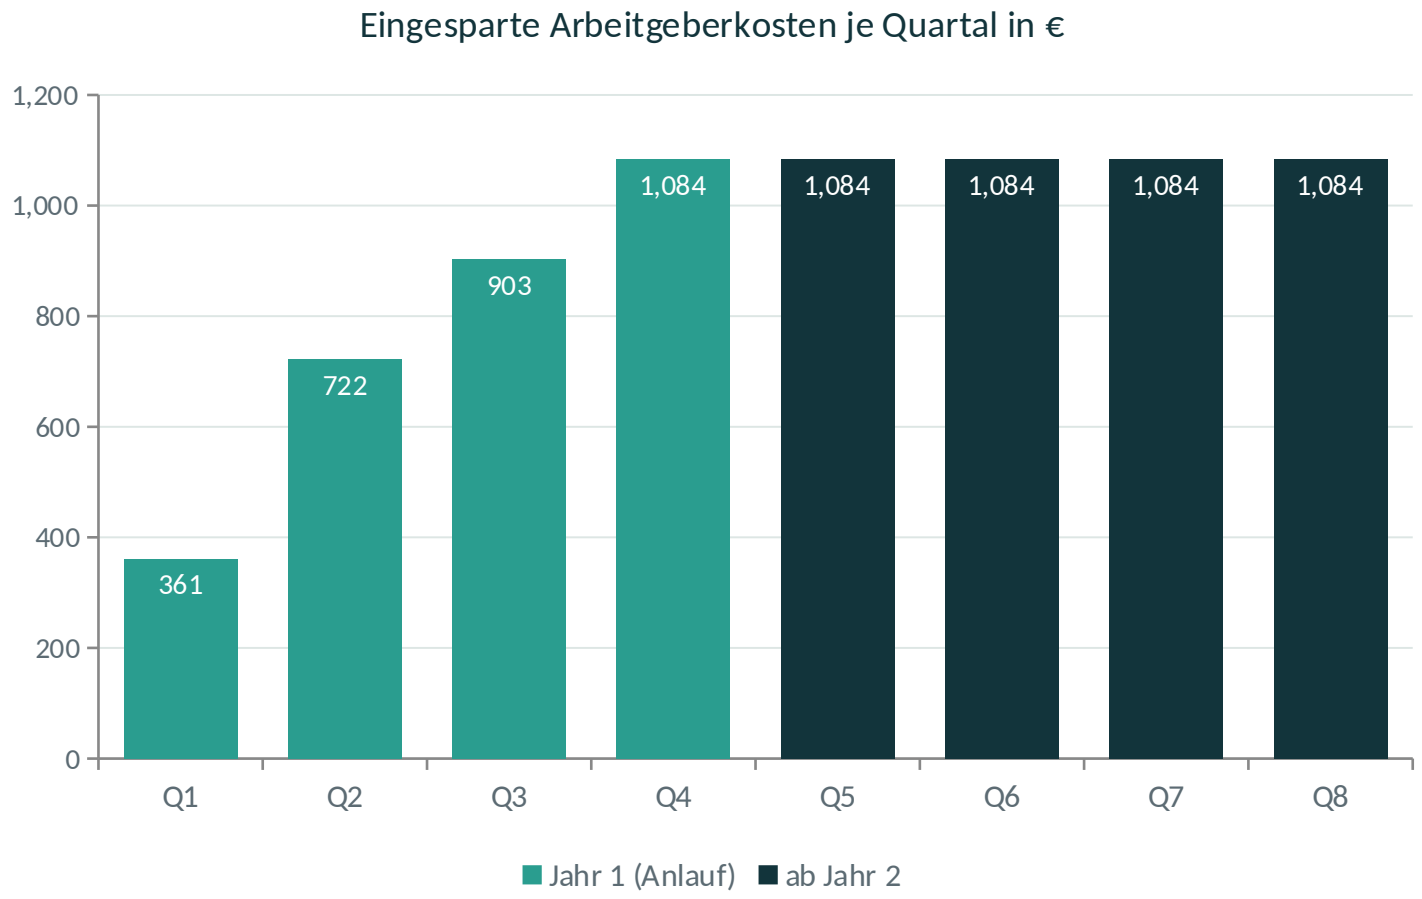
Warum dieser Pilot

- Trifft das größte Problem: 90 % der Fehler
- Regeln sind öffentlich und belegbar (G-BA, KBV)
- Keine Schnittstelle nötig: Eingabe per Chat oder Formular
- Geringes Risiko: Die Rezeption entscheidet
- Messbar: Zeit, Trefferquote, Nacharbeit

Einschätzung des Teams, keine Messung · im Pilot nur für den Verordnungs-Check überprüft

Soll: Prüfung vor der Behandlung, 75 % weniger Prüfzeit

Thomas



Jahr 1

≈ 3.070 €

146 h frei · Anlauf 25 → 75 %

ab Jahr 2

≈ 4.300 € / Jahr

207 h frei · etwa ½ Minijob

Der Hebel ist die Prüfzeit, nicht die Absetzungen (nur ca. 500 € pro Jahr). Ziel: einen zusätzlichen Minijob bei Wachstum vermeiden, keine Stelle ersetzen.

Annahmen: 5,3 h/Woche × 13 Wochen je Quartal · Mindestlohn 2026 + 15 % = 15,99 €/h, mit Minijob-Abgaben ≈ 20,97 €/h · Betriebskosten noch gegenzurechnen

Tool-Vergleich: Kriterien, Kandidaten, Ergebnis

Valentin

ENTWURF

Kriterien laut IHK: Funktionalität · Datenschutz · Benutzerfreundlichkeit · Integrationsfähigkeit · Kosten

Baustein	Kandidaten	Gewählt
Orchestrierung	n8n, Make, Copilot Studio, eigener Code	n8n (MSIT-Vorgabe, trotzdem bewertet)
Sprachmodell	gpt-4.1-mini, größere Modelle, Modelle mit EU-Hosting	gpt-4.1-mini
Wissensbasis (RAG)	Supabase pgvector, eigenständige Vektordatenbank	Supabase pgvector (EU-Region)
Eingabekanal	Chat-Text, Webformular, Foto + Vision-KI, Scan + OCR, E-Mail, Praxissoftware, E-Verordnung	Chat und Formular heute, Foto als Brücke

Ergebnis TCO-Vergleich

KI-Kosten

70–142 € / Jahr

Gesamtkosten je Eingabekanal

823–2.054 € / Jahr

Die Eingabezeit der Rezeption bestimmt die Kosten, nicht die KI.

Praxistest: Prototyp v1–v4 · ca. 3–4 Cent je Prüfung (Schätzung aus Token, noch keine gemessene Abrechnung) · offen: Gewichtung der Kriterien, Preisquellen mit Abrufdatum

Tool-Auswahl und Architektur: Regeln rechnet der Code

Valentin

Eingang

Chat oder Formular (Muster 13)

Erfassen

LLM füllt festes Schema, PII entfernt

Fakten

Code: Fristen, Formate, ICD → Diagnosegruppe

4 Prüfer

Formal · Diagnose · Mengen · Fristen

Ampel

Code: grün / gelb / rot mit Fundstelle

Dunkel = deterministischer Code, hell = Sprachmodell

Stack

- n8n Cloud: Workflow, Chat, Formular
- OpenAI gpt-4.1-mini, Temperatur 0,1
- Supabase pgvector (EU): ca. 380 Abschnitte aus HeilM-RL, Heilmittelkatalog, KBV-Diagnoseliste
- GitHub: Exporte, Tests, Doku

Entscheidung beim Zusammenführen der Workflows

Embedding-Modell: zwingend text-embedding-3-small, weil es zur geladenen Wissensbasis passen muss. Vektoren eines anderen Modells wären nicht vergleichbar.

Chat-Modell: bewusst vereinheitlicht auf gpt-4.1-mini, damit alle Testergebnisse vergleichbar bleiben. Technisch wäre ein anderes Modell möglich.

Leitsatz: Was sich als Regel aufschreiben lässt, rechnet der Code, nicht das Sprachmodell · jeder Befund nennt seine Fundstelle im Regelwerk

Governance: Mensch entscheidet, Daten geschützt

Valentin

ENTWURF

EU AI Act

- Vorläufig kein Hochrisiko-System: prüft Formalien, entscheidet nicht über Behandlung
- Transparenz: Nutzer wissen, dass sie mit KI arbeiten (Art. 50)
- KI-Kompetenz: Einweisung der Rezeption (Art. 4)
- Kein Medizinprodukt (zu bestätigen)

DSGVO

- Verordnungen sind Gesundheitsdaten (Art. 9)
- Prototyp: nur synthetische Daten
- Echtbetrieb: Pseudonym, Auftragsverarbeitung, EU-Hosting, Löschkonzept
- Datenschutz-Folgenabschätzung prüfen (Art. 35)

Aufsicht und Sicherheit

- Ampel ist eine Empfehlung, die Rezeption entscheidet
- Jeder Befund nennt seine Fundstelle
- Jede Prüfung wird protokolliert
- Chat und Formular erst mit Anmeldung öffentlich, Schlüssel nie im Repository

Offen: EU-AI-Act-Einordnung prüfen und belegen (Sprint 3)

Prototyp: Stand 20.10.2026

Derk

Zwei Workflows

Merge-Workflow (neu)
Valentins Formular + vier Prüfer in einem Flow: Chat und Muster-13-Formular, PII-Redaktion, Diagnoseauswahl

Vier Prüfer v4 (Fallback)
unverändert, falls der Merge kurz vor der Prüfung Probleme macht

Noch nicht öffentlich: erst mit aktiver Anmeldung (Kostenrisiko)

Tests des Merge-Workflows

Testfall 1 als Daten (Chat)
grün, 18 von 18 Befunden ok, ca. 30 s

Testfall 3 als Freitext mit Patientendaten
rot korrekt (WS statt EX), Patientendaten entfernt · aber ein Fehlalarm im Mengen-Prüfer

Eingabe über das Formular
grün, 18 von 18 ok, 6 personenbezogene Felder ersetzt

Diese Woche: Mengen-Prüfer schärfen (nur Mengen bewerten, Diagnose ist nicht sein Mandat), dann Verordnungsfall-Prüfung (v5) mit Historie, Frühwarnung Mi 21.10.

Tests vom 20.10.2026 · synthetische Testfälle · WS = Wirbelsäule, EX = Extremitäten

Erfolgsmessung: ≥ 98 % auf 50 neuen Fällen

Derk

ENTWURF

Zielwert

≥ 98 %

richtige Ampel, höchstens 1 Fehler bei 50 Fällen, jeder Fall 3 Läufe = 150 Prüfungen

Bedingt bereit: 95–98 % · nicht bereit: < 95 %

Harte Bedingungen

- 0 übersehene rote Verordnungen
- ≤ 1 kritischer Fehlalarm
- Verordnungsfall-Summe 100 % exakt
- Fundstelle bei 100 % der Befunde
- Stabilität ≥ 95 % über 3 Läufe
- ≤ 30 s und ≤ 5 Cent je Prüfung

Bisher (v4, 10 Fälle)

10 / 10

Ampeln korrekt, 0 kritische Fehlalarme (Start: 12) · zählt nicht als formale Evaluation

Testset Sprint 3 (26.–30.10.)

- **≥ 12** grün
- **≥ 8** gelb
- **≥ 25** rot
- **≥ 5** Grenzfall

Referenzstandard: ausschließlich die Regelwerke · Soll-Ampel und Fundstelle je Fall vorher festgelegt · Ergebnis folgt nach Sprint 3

Einsatzplanung: vom Parallelbetrieb zum Regelbetrieb

Derk

ENTWURF

0 · Vorbereitung

2 Wochen

- Chat mit Anmeldung
- Auftragsverarbeitung geklärt
- Einweisung Inhaberin und Rezeption

Weiter, wenn:

Datenschutz freigegeben

1 · Parallelbetrieb

6 Wochen

- Rezeption prüft wie bisher
- System läuft mit
- Abweichungen werden protokolliert

Weiter, wenn:

≥ 98 % Übereinstimmung, 0 übersehene rote

2 · Unterstützt

bis Ende Q2

- System prüft zuerst
- Mensch bestätigt die Ampel
- Schlussprüfung bleibt

Weiter, wenn:

Prüfzeit −50 %

3 · Regelbetrieb

ab Q3

- Doppelabrechnungs-Prüfung
- Foto-Upload der Verordnung
- Monatlicher Qualitätsbericht

Weiter, wenn:

Prüfzeit −75 %

Verantwortlich in der Praxis: Inhaberin · Parallelbetrieb von der Praxis zugesagt (Field Study) · Rückfallebene: Prüfung wie heute, ohne System

Phasen entsprechen dem Einsparziel 50 % / 75 % · Dauer der Phasen noch mit der Praxis abzustimmen

Reflexion: Was wir gelernt haben

Thomas

ENTWURF

Fehler finden war leicht, Fehlalarme senken war die Arbeit

Baseline: alle 8 Fehler erkannt, aber 12 kritische Fehlalarme

Regeln gehören in den Code

Das Sprachmodell nur dort, wo Sprachverständnis nötig ist

Die Field Study hat den Schwerpunkt verschoben

90 % der Fehler bei Folgeverordnungen → Verordnungsfall-Prüfung zuerst

Zusammenführen braucht Kompatibilität

Embedding-Modell und Wissensbasis gehören zusammen; Fallback-Version behalten

Für künftige Projekte

- Erst Field Study, dann bauen
- Früh messen, Testfälle vor dem Tuning trennen
- Tool-Auswahl regelmäßig überprüfen: E-Verordnung über die TI (Anschlusspflicht ab 1.10.2027) macht Texterkennung zur Übergangslösung

Umfang von Kapitel 6 (Reflexion, roter Faden, Fazit) noch mit dem Tutor zu klären

Fazit: Fehler vor der Behandlung finden

Thomas

≥ 98 %

Zielquote des Systems

gegen höchstens ca. 85 % bei menschlicher Doppelkontrolle

vorher

statt nachher

Fehler fallen vor der Behandlung auf, nicht erst bei der Abrechnung

≈ 4.300 €

pro Jahr ab Jahr 2

etwa ½ Minijob an Prüfzeit frei für Patienten und Telefon

Unsere Empfehlung

Pilot im Parallelbetrieb starten: sechs Wochen mitlaufen lassen, messen, dann entscheiden. Die Rezeption behält die Entscheidung und gewinnt Zeit für die Patienten.