KI-EINSATZ-PLANUNG · VERORDNUNGS-CHECK · GRUPPE 1

Kapitel 3: Tools vergleichen

Physiotherapiepraxis (anonymisiert) · Endfassung · Stand 27.10.2026

Kapitel 2 hat den Verordnungs-Check als ersten Einsatzbereich festgelegt. Eine solche Lösung besteht nicht aus einem einzelnen Werkzeug, sondern aus mehreren Bausteinen: einer Plattform, die den Ablauf steuert, einem Sprachmodell, einer Wissensbasis mit den Regelwerken und einem Eingabekanal für die Rezeption. Dieses Kapitel leitet aus der Ist- und Soll-Situation die Anforderungen ab, stellt einen gewichteten Kriterienkatalog auf und vergleicht je Baustein die Kandidaten, auf dem Papier und im Praxistest.

1 Vorgehen

1. **Anforderungen** aus der Ist- und Soll-Situation ableiten.
2. **Kriterienkatalog** mit den Kriterien Funktionalität, Datenschutz, Benutzerfreundlichkeit, Integrationsfähigkeit und Kosten aufstellen und gewichten.
3. **Vorauswahl:** je Baustein zwei bis fünf Kandidaten.
4. **Praxistest:** einen Prototyp in mehreren Versionen bauen und messen.
5. **Fazit:** Auswahl je Baustein, begründet in Kapitel 4.

Eine Einschränkung nennen wir offen: Die Plattform n8n war im Rahmen der Weiterbildung vorgegeben. Wir haben sie trotzdem gegen die Alternativen bewertet, denn eine Vorgabe ersetzt keine Begründung. Echte Wahlfreiheit hatten wir beim Sprachmodell, bei der Wissensbasis und beim Eingabekanal.

2 Anforderungen

Anforderung aus der Ist- und Soll-Situation	Kriterium
Jeder Befund mit Fundstelle aus öffentlichen Regelwerken; die Regeln ändern sich jährlich; Fristen und Mengen müssen exakt stimmen	Funktionalität
Verordnungen sind Gesundheitsdaten; Daten in der EU, Pseudonym statt Name, Schweigepflicht der Praxis	Datenschutz
Die Rezeption hat keine IT-Kenntnisse: Formular oder Chat, Antwort in Sekunden	Benutzerfreundlichkeit
Keine Schnittstelle zur Praxissoftware nötig; Protokoll jeder Prüfung; Historie je Verordnungsfall	Integrationsfähigkeit
Laufende Kosten klein gegenüber der eingesparten Zeit, Ziel höchstens 5 Cent je Prüfung	Kosten

3 Kriterienkatalog

Kriterium	Gewicht	Begründung
Funktionalität	30 %	Ein Werkzeug, das falsch prüft, ist wertlos, egal wie günstig es ist
Datenschutz	25 %	Gesundheitsdaten und Berufsgeheimnis; ein Verstoß gefährdet die Praxis
Benutzerfreundlichkeit	15 %	Die Rezeption arbeitet unter Zeitdruck

Kriterium	Gewicht	Begründung
Integrationsfähigkeit	15 %	Datenbank, Protokoll und Historie müssen angebunden sein
Kosten	15 %	Laut Kapitel 1 klein gegenüber dem Nutzen, deshalb geringer gewichtet

Bewertet wird je Kriterium mit 1 (schlecht) bis 5 (sehr gut). Die gewichtete Summe ergibt einen Wert zwischen 1 und 5.

4 Vergleich je Baustein

Orchestrierung

Kandidat	Funktion	Datenschutz	Bedienung	Integration	Kosten	Gewichtet
n8n	5	4	4	5	4	**4,45**
Eigener Code (z. B. Python)	5	4	2	4	3	3,85
Microsoft Copilot Studio	3	4	5	2	2	3,25
Reine Regel-Engine ohne KI	1	5	3	3	4	3,05

n8n vereint Agenten, Vektorsuche und Code-Knoten in einem Workflow, hat fertige Anbindungen an OpenAI und Supabase und lässt sich als Datei exportieren und versionieren. Schwächen sind das fehlende eigene Frontend und die nötigen JavaScript-Kenntnisse für Code-Knoten. **Eigener Code** bietet volle Kontrolle, kostet aber mehr Bauzeit und ist für die Praxis schwerer zu warten. **Copilot Studio** hat eine gute Chat-Oberfläche, die Anbindung einer eigenen Datenbank und eigener Rechenlogik ist dort aber umständlicher, die Lizenzkosten sind höher. Eine **reine Regel-Engine** wäre deterministisch, scheidet aber aus: Die Eingabe ist Freitext, und die Regeln stehen in langen PDF-Dokumenten. Ein eigenes Frontend haben wir ebenfalls erwogen und verworfen; es kostet Bauzeit ohne Prüfnutzen.

Sprachmodell

Kandidat	Funktion	Datenschutz	Bedienung	Integration	Kosten	Gewichtet
gpt-4.1-mini (Temperatur 0,1)	4	3	5	5	5	**4,20**
Modell mit EU-Hosting	3	5	4	4	4	3,95
Größeres Modell	4	3	4	5	3	3,75

Getestet wurde gpt-4.1-mini. Die Werte der beiden anderen Kandidaten sind Einschätzungen.

Das kleine Modell reicht, weil die harten Regeln im Code gerechnet werden. Das Modell muss lesen, suchen und formulieren. Es braucht rund 25 Sekunden und 3 bis 4 Cent je Prüfung; die niedrige Temperatur macht die Ergebnisse reproduzierbarer. Ein größeres Modell kostet mehr und antwortet langsamer, und unser wichtigster Fehler, die falsche Zuordnung eines ICD-Codes, wurde nicht durch Modellgröße gelöst, sondern durch Code. Ein Modell mit EU-Hosting hat den klaren Datenschutzvorteil. Weil der Prototyp nur synthetische Daten verarbeitet, bewerten wir das vor einem Echtbetrieb neu; OpenAI bietet für API-Projekte inzwischen auch eine Datenhaltung in Europa an.

Für die Vektorsuche nutzen wir **text-embedding-3-small**. Die Wissensbasis ist mit diesem Modell geladen, und Suchanfragen müssen mit demselben Modell eingebettet werden. Embeddings eines anderen Anbieters liegen in einem anderen Vektorraum; die Suche wäre wertlos, solange die Wissensbasis nicht vollständig neu geladen wird.

Wissensbasis

Ansatz	Bewertung	Ergebnis
RAG: Regelwerke als Abschnitte in einer Vektorsuche	Jeder Befund kann seine Fundstelle nennen; eine neue Fassung wird per Knopfdruck neu geladen	**gewählt**
Fine-Tuning des Modells	Die Regeln ändern sich jährlich, jedes Mal neu trainieren; keine überprüfbare Fundstelle; teuer	verworfen
Gesamte Regelwerke im Prompt	Hunderte Seiten je Prüfung, hohe Kosten und lange Wartezeit	verworfen
Supabase mit pgvector, Region Frankfurt	Eine Datenbank für Wissensbasis, Protokoll und Historie; Zugriffsschutz auf Zeilenebene	**gewählt**
Eigenständige Vektordatenbank	Zweites System mit eigenem Vertrag und Zugang, ohne Mehrwert bei rund 380 Abschnitten	verworfen

Die Wissensbasis umfasst 380 Abschnitte: 236 aus der Heilmittel-Richtlinie, 82 aus dem Heilmittelkatalog und 62 aus der KBV-Diagnoseliste. Alle Quellen sind frei zugänglich. Die ICD-10-GM ist bewusst nicht vollständig hinterlegt, weil ihr Download einen Nutzungsvertrag mit dem BfArM begründet.

Eingabekanal

Kanal	Stand	Bewertung
Formular nach Muster 13	umgesetzt	Strukturiert, kein Erfassungsfehler; Patientendaten werden ersetzt, bevor das Modell sie sieht
Chat (Text oder strukturiert)	umgesetzt	Schnell für Rückfragen; Freitext muss erst erfasst werden
Foto mit Bilderkennung	Prototyp	Bequem, aber Lesefehler; Brücke bis zur elektronischen Verordnung. Im Test las das Modell den Text zuverlässig, die Ankreuzfelder oft falsch; deshalb kontrolliert die Rezeption die erkannten Werte, bevor geprüft wird.
Scan mit Texterkennung, E-Mail, Messenger	verworfen	Mehr Arbeitsschritte oder unsicherer Kanal für Gesundheitsdaten
Praxissoftware, elektronische Verordnung	Ausblick	Beste Lösung, braucht aber eine Schnittstelle

5 Praxistest

Die Bausteine haben wir nicht nur auf dem Papier bewertet, sondern in einem Prototyp gebaut und gemessen. Die Einzelheiten stehen in Kapitel 5.

Version	Stand	Ergebnis
v1	alle Prüfungen durch das Sprachmodell	alle 8 eingebauten Fehler erkannt, aber 12 kritische Fehlalarme
v2 und v3	verbesserte Anweisungen an das Modell	weniger Fehlalarme, die Zuordnung von ICD-Codes blieb fehlerhaft
v4	Fristen, Formate und ICD-Zuordnung im Code	10 von 10 Ampeln korrekt, keine kritischen Fehlalarme, ca. 24 s und 3–4 Cent je Prüfung
Zusammenführung	Formular und Chat, Patientendaten ersetzen, weitere Regeln im Code	Fehlalarme behoben; Hinweis auf besonderen Verordnungsbedarf per Anweisung noch unzuverlässig

Version	Stand	Ergebnis
Cloud, Lauf 1	Zusammenführung unverändert in n8n Cloud, Freitext-Redaktion als Regel-Code	Testbatterie (Blindtest): 83,1 % richtige Ampeln, 5 übersehene rote Verordnungen
Cloud, Lauf 2	fünf weitere Regeln im Code	96,6 % richtige Ampeln, keine übersehene rote Verordnung, ca. 34 s und 3 Cent je Prüfung (Kapitel 5)

Der Test hat die Auswahl bestätigt und eine Grenze gezeigt: Tabellen aus PDF-Dokumenten liest das Modell unzuverlässig. Deshalb gehört auch die KBV-Diagnoseliste als Tabelle in den Code.

6 Gesamtkosten

70–142 €
Modellkosten pro Jahr

823–2.054 €
Gesamtkosten pro Jahr je Eingabekanal, einschließlich Eingabezeit

≤ 5 Cent
Zielwert je Prüfung, Schätzung heute 3–4 Cent

Zur Plausibilisierung: 40 Verordnungen pro Woche ergeben rund 2.080 Prüfungen im Jahr, bei 3 bis 4 Cent also etwa 62 bis 83 € reine Prüfkosten. Hinzu kommen die Abonnements für n8n und Supabase mit n8n Starter für 20 € im Monat bei jährlicher Zahlung, also 240 € im Jahr (2.500 Ausführungen im Monat, gebraucht werden rund 175), und Supabase Pro ab 25 US-Dollar im Monat, rund 300 US-Dollar im Jahr; der kostenlose Supabase-Tarif scheidet für den Betrieb aus, weil er Projekte nach einer Woche ohne Nutzung pausiert (Preise abgerufen am 27.10.2026). Das wichtigste Ergebnis: Die Gesamtkosten bestimmt die Eingabezeit der Rezeption, nicht die KI. Das spricht für den Kanal mit der kürzesten Eingabezeit und der geringsten Nacharbeit, das strukturierte Formular.

7 Fazit

Baustein	Auswahl
Orchestrierung	n8n Cloud
Sprachmodell	OpenAI gpt-4.1-mini, Temperatur 0,1; vor einem Echtbetrieb EU-Hosting neu bewerten
Embeddings	OpenAI text-embedding-3-small
Wissensbasis	RAG mit Supabase pgvector in der Region Frankfurt
Eingabekanal	Formular nach Muster 13 und Chat; Foto als Option

Wie diese Bausteine zusammenspielen, warum sie die Anforderungen erfüllen und wie der Einsatz in der Praxis geplant ist, beschreibt Kapitel 4.

QUELLEN

- Eigener Prototyp: Testläufe vom 13.10.2026 (v1–v4), 20.–23.10.2026 (Zusammenführung) und 27.10.2026 (Testbatterie in der Cloud), Änderungsprotokoll
- Gemeinsamer Bundesausschuss: Heilmittel-Richtlinie, Heilmittelkatalog; KBV: Diagnoseliste Heilmittel; BfArM: ICD-10-GM
- Kostenschätzung aus dem eigenen TCO-Vergleich der Eingabekanäle vom 19.10.2026
- n8n: Plans and Pricing, n8n.io/pricing; Supabase: Pricing, supabase.com/pricing; beide abgerufen am 27.10.2026