KI-EINSATZ-PLANUNG · VERORDNUNGS-CHECK · GRUPPE 1

Kapitel 5: Erfolg messen

Physiotherapiepraxis (anonymisiert) · Endfassung · Stand 27.10.2026

Kapitel 1 hat die Ziele festgelegt, Kapitel 4 den Weg in den Betrieb geplant. Dieses Kapitel beschreibt, woran wir den Erfolg messen. Wir messen auf zwei Ebenen: vor dem Einsatz, ob das System richtig und vollständig prüft, und im Einsatz, ob die Praxis Zeit spart und die Rezeption dem System vertraut. Aus beiden Messungen leiten wir Folgerungen für Optimierung und Schulung ab.

1 Erfolgskriterien

Maßstab sind ausschließlich die Regelwerke: Heilmittel-Richtlinie, Heilmittelkatalog und KBV-Diagnoseliste. Für jeden Testfall legt das Team vor dem Testlauf die Soll-Ampel, jeden erwarteten Befund und die Fundstelle fest. Ein Fall ohne belegte Fundstelle wird nicht gewertet. Erfahrungen der Praxis fließen nur in die Auswahl der Fälle ein, nicht in die Bewertung.

Ampel	Bedeutung
rot	mindestens ein Befund „fehlt“ oder „fehlerhaft“: So behandelt, droht die Absetzung
gelb	kein roter Befund, aber mindestens ein Hinweis, etwa auf eine überschrittene orientierende Menge oder einen besonderen Verordnungsbedarf
grün	keine Befunde außer „in Ordnung“

≥ 98 %
richtige Ampeln auf mindestens 50 neuen Fällen

0
übersehene rote Verordnungen

≤ 1
kritischer Fehlalarm über alle Fälle

100 %
exakte Summe im Verordnungsfall

Die primäre Kennzahl ist die Ampel-Trefferquote auf Fällen, die nie zum Nachbessern verwendet wurden. Jeder Fall läuft dreimal; gewertet wird die Ampel, die mindestens zweimal kam. Unabhängig von der Quote gelten drei harte Bedingungen: Eine übersehene rote Verordnung ist der teure Fehler, denn die Kasse setzt ab. Zu viele Fehlalarme führen dazu, dass die Rezeption das Werkzeug ignoriert. Und die Summe im Verordnungsfall ist eine reine Rechnung, bei der es keine Toleranz gibt.

Sekundäre Kennzahl	Ziel
Befund-Genauigkeit: richtiger Prüfer, richtiges Feld	≥ 95 %
Fundstelle bei jedem Befund, der nicht „in Ordnung“ ist	100 %
Stabilität: gleiche Ampel in allen drei Läufen	≥ 95 % der Fälle
Laufzeit je Prüfung	≤ 30 s
Kosten je Prüfung	≤ 5 Cent

Unter 95 % oder bei einer übersehenen roten Verordnung gilt das System als **nicht bereit**. Zwischen 95 und 98 % gilt es als **bedingt bereit**: Die Ursachen werden einzeln benannt, die Schwelle wird nicht nachträglich gesenkt.

Warum 98 % und warum 50 Fälle? Die Praxis schätzt die Wirksamkeit menschlicher Doppelkontrollen auf höchstens 85 %; 98 % sind ein deutlicher Fortschritt. Mit zwölf Fällen ließe sich das nicht messen, schon ein Fehler ergäbe 92 %. Erst ab 50 Fällen erlaubt das Ziel genau einen Fehler. Auch 50 Fälle sind ein Funktionsnachweis und kein statistischer Beweis für den Betrieb; dafür dient der Parallelbetrieb.

2 Bisherige Ergebnisse des Prototyps

Kennzahl	Version 1 (7 Fälle)	Version 4 (10 Fälle)
Erwartete Fehler erkannt	8 von 8	9 von 9

Kennzahl	Version 1 (7 Fälle)	Version 4 (10 Fälle)
Ampel korrekt	6 von 7	**10 von 10**
Kritische Fehlalarme	12	**0**
Unnötige Hinweise	10	0
Laufzeit je Prüfung	26,0 s	24,0 s
Kosten je Prüfung (Schätzung)	3–4 Cent	3–4 Cent

Erkannt hat das System die Fehler von Anfang an. Die eigentliche Arbeit war, die Fehlalarme zu senken, denn eine Rezeption, die bei jeder korrekten Verordnung Rot sieht, ignoriert das Werkzeug nach einer Woche.

> **Wichtigster Fehlermodus**
> Das Sprachmodell „weiß" Dinge falsch, und zwar mit Begründung. In Version 3 ordnete es den Knie-Code S83.5 der Wirbelsäule zu, mit Fundstelle und plausibler Erklärung. Für die Rezeption ist ein solcher Fehler kaum zu erkennen. Bessere Anweisungen halbierten ihn, beseitigten ihn aber nicht. Erst die Zuordnung im Code löste ihn.

Diese Zahlen zählen ausdrücklich nicht als formale Evaluation: Sieben der zehn Fälle wurden zum Nachbessern verwendet, und die Kriterien entstanden erst danach. Nach der Zusammenführung zweier Entwicklungsstände haben wir 20 weitere Läufe auf Entwicklungsfällen durchgeführt; 13 waren einwandfrei. Die Fehlalarme wurden behoben. Offen blieben ein Abbruch, weil eine Modellantwort nicht ins Schema passte, und der Hinweis auf besonderen Verordnungsbedarf: Das Modell findet den Eintrag in der KBV-Liste, wertet ihn aber als „in Ordnung".

3 Testbatterie für die formale Evaluation

Für die formale Evaluation haben wir 100 neue synthetische Fälle angelegt und vor dem ersten Lauf in zwei Sets getrennt.

Set	Zweck	Fälle	grün	gelb	rot	Grenzfälle
Evaluation	nur zur Messung, nie zum Nachbessern	65	20	10	35	8
Entwicklung	darf zum Nachbessern genutzt werden	35	11	5	19	4

Das Evaluationsset erfüllt die Vorgaben: mindestens 12 grüne, 8 gelbe und 25 rote Fälle, je Prüfer mindestens fünf rote (Formal 10, Diagnose 10, Mengen 9, Fristen 10), mindestens fünf Grenzfälle genau an einer Frist oder Mengengrenze. Alle Fälle haben ein festes Prüfdatum, damit die Fristen bei jedem Lauf gleich ausfallen. Kein ICD-Code aus den Fällen steht in den Anweisungen an das Modell. Bei drei Läufen je Fall sind das 195 Prüfungen. Ein kompletter Lauf über alle 123 Fälle mit 253 Prüfungen dauerte mit vier parallelen Prüfungen rund 45 Minuten. Zehn Fälle setzen die Verordnungsfall-Prüfung voraus und werden nur gewertet, wenn sie umgesetzt ist.

4 Ergebnis der formalen Evaluation

Gemessen am 27.10.2026 in der n8n Cloud, gegen alle 123 Testfälle aus Supabase (65 Evaluations-, 35 Entwicklungsfälle, 23 Fälle aus der Prüfvorlage), jedes Ergebnis in der Tabelle *testlaeufe* protokolliert. Gewertet sind die 59 Evaluationsfälle ohne Verordnungsfall-Prüfung, je dreimal. Lauf 1 ist der Blindtest des zusammengeführten Stands. Danach haben wir fünf Regeln aus dem Code-Leitsatz umgesetzt und Lauf 2 gefahren; ein Nachtest prüfte eine letzte Korrektur am Formal-Prüfer (15 Prüfungen).

Kennzahl	Ziel	Lauf 1	Lauf 2	nach Nachtest	erfüllt
Ampel korrekt	≥ 98 %	83,1 %	94,9 %	**96,6 %**	nein
Übersehene rote Verordnungen	0	5	0	**0**	ja

Kennzahl	Ziel	Lauf 1	Lauf 2	nach Nachtest	erfüllt
Kritische Fehlalarme	≤ 1	2	2	**1**	ja
Summe im Verordnungsfall exakt	100 %		nicht gemessen, Prüfung noch nicht umgesetzt		offen
Befund-Genauigkeit	≥ 95 %	79,7 %	84,8 %	–	nein
Fundstelle vorhanden	100 %	97,3 %	98,8 %	–	nein
Stabilität über drei Läufe	≥ 95 %	94,9 %	96,6 %	–	ja
Laufzeit (Median)	≤ 30 s	34,5 s	34,4 s	–	nein
Kosten je Prüfung	≤ 5 Cent	ca. 3 US-Cent (Schätzung aus der Token-Zählung, rund 57.000 Eingabe-Token je Prüfung)			ja

Zwei Soll-Werte wurden vor Lauf 2 korrigiert und für beide Läufe gleich angewandt: Frequenz außerhalb von 1–3× pro Woche ist ein Hinweis (gelb, Teamentscheidung); Leitsymptomatik „c" bei EX ist fehlerhaft (Heilmittelkatalog nennt nur a, b und x).

Bewertung: bedingt bereit für die Prüfung der einzelnen Verordnung, Stand 27.10.2026, Cloud-Workflow mit Regeln im Code, 59 Fälle × 3 Läufe. Die beiden harten Bedingungen zu roten Verordnungen und Fehlalarmen sind erfüllt. Verfehlt sind: die Ampelquote mit zwei Fällen, ein Freitext, bei dem die Diagnosegruppe nicht erkannt wurde, und ein übersehener Hinweis auf besonderen Verordnungsbedarf; die Befund-Genauigkeit, weil das Modell Befunde teils unter anderem Feldnamen meldet; zwei Befunde ohne Fundstelle; die Laufzeit um rund 4 Sekunden. Die Verordnungsfall-Prüfung ist nicht umgesetzt, die zehn Fälle dazu sind nicht gewertet. Methodisch wichtig: Lauf 2 ist kein Blindtest mehr, denn die Regeln entstanden aus den Fehlern von Lauf 1. Es sind allgemeine Regeln aus dem Regelwerk, keine Anpassungen an einzelne Fälle; trotzdem gilt nur Lauf 1 als unverfälschte Messung.

Fehler in Lauf 1	Fälle	Ursache	Lösung bis Lauf 2
Höchstmenge, ergänzende Heilmittel	3	Modell bestätigte z. B. 8 Einheiten bei EX trotz Summe als Fakt	Code-Urteil, Modell kann es nicht überstimmen
Leitsymptomatik	2	Regel war bei der Zusammenführung entfallen	wieder im Code: WS und EX nur a, b, x
Unzulässiges ergänzendes Heilmittel	1	Traktion bei EX nicht erkannt	Liste je Diagnosegruppe im Code
Frequenz	1	Formal-Prüfer bewertete den Inhalt statt nur das Vorhandensein	Code entscheidet Frequenzrahmen und Vorhandensein
Besonderer Verordnungsbedarf	2	Modell liest die KBV-Tabelle unzuverlässig	offen: Maßnahme 1
Freitext-Erfassung	1	„WS" ohne Feldbezeichnung nicht als Diagnosegruppe erkannt	offen: Formularweg empfehlen

5 Messung im Pilot

Im Parallelbetrieb messen wir, was keine synthetische Evaluation zeigen kann.

Was	Wie	Ziel
Übereinstimmung	Ampel des Systems gegen das Ergebnis der Rezeption; jede Abweichung wird geklärt: Wer hatte recht?	≥ 98 %, keine übersehene rote Verordnung
Prüfzeit	Stoppuhr-Stichprobe von 20 Verordnungen je Messung, vorher und nachher	−50 % nach zwei, −75 % nach vier Quartalen

Was	Wie	Ziel
Akzeptanz	Wie oft folgt die Rezeption der Ampel, wie oft öffnet sie die Fundstelle? Kurze Rückmeldung nach jeder Woche	Die Rezeption folgt der Ampel, Fehlalarme werden gemeldet
Absetzungen	Zahl und Betrag gegenüber dem Vorjahr	Zusatznutzen, nicht Teil des Business Case

Auch die Fälle, in denen die Rezeption richtig und das System falsch lag, sind ein Ergebnis. Sie gehen als neue Testfälle in das Entwicklungsset.

6 Folgerungen für Optimierung und Schulung

Nr.	Maßnahme	Nutzen
1	KBV-Einträge für Wirbelsäule und Extremitäten als Tabelle im Code; das Modell formuliert nur noch	Gelbe Fälle werden zuverlässig erkannt
2	Automatische Wiederholung bei Schemafehlern und Verbindungsabbrüchen (ein Abbruch in Lauf 2)	keine Abbrüche in der Stabilitätsmessung
3	10 bis 20 anonymisierte echte Verordnungen als Testfälle, mit Einwilligung	Fehlerarten, an die das Team nicht gedacht hat
4	ICD-Zuordnung im Code um weitere Diagnosegruppen erweitern	weniger Abhängigkeit vom Modell
5	Kosten aus der Abrechnung des Modellanbieters statt Schätzung	belastbarer Business Case
6	Laufzeit senken: Regelwerk-Suche je Prüfer bündeln, Fristen-Prüfer ganz in Code	Ziel ≤ 30 s
7	Verordnungsfall-Prüfung umsetzen und die zehn zurückgestellten Fälle werten	wichtigster Ausbau, 90 % der Fehler laut Field Study

Die Messung liefert auch die Inhalte der Schulung. Jeder Fehlermodus aus der Evaluation wird in der Einweisung als Beispiel gezeigt: So sieht ein plausibler, aber falscher Befund aus. Häufen sich im Parallelbetrieb Abweichungen bei einem Prüfer, wird je nach Ursache nachgeschult oder der Prüfer verbessert. Was wir aus dem gesamten Vorgehen gelernt haben, fasst Kapitel 6 zusammen.

QUELLEN

- Eigene Erfolgskriterien vom 19.10.2026 und Evaluation vom 13.10.2026; Änderungsprotokoll vom 20. und 23.10.2026
- Eigene Testbatterie mit 100 synthetischen Fällen, Prüfdatum 26.10.2026; automatische Tests für die Code-Knoten (71 von 71 bestanden)
- Testläufe vom 27.10.2026 in n8n Cloud, Workflow „Verordnungs-Check – Cloud“, protokolliert in Supabase (Tabelle testlaeufe); Preise gpt-4.1-mini laut OpenAI-Modellseite, abgerufen am 27.10.2026