KI-EINSATZ-PLANUNG · VERORDNUNGS-CHECK · GRUPPE 1

Kapitel 6: Reflexion und roter Faden

Physiotherapiepraxis (anonymisiert) · Endfassung · Stand 27.10.2026

Die Kapitel 1 bis 5 haben ein Problem beschrieben, Einsatzfelder bewertet, Werkzeuge verglichen, eine Lösung gebaut und ihre Messung festgelegt. Dieses Kapitel blickt auf den Weg zurück. Es fasst den roten Faden zusammen, benennt, was wir gelernt haben, leitet daraus ein Vorgehen für künftige KI-Einführungen ab und zeigt, warum die heutige Auswahl nicht statisch ist.

1 Der rote Faden

Die Arbeit folgt einer Linie: **weniger Verwaltung, mehr Zeit für Patienten.**

1. **Problem:** Die Rezeption prüft jede Kassenverordnung von Hand, rund 5,3 Stunden pro Woche. Trotzdem rutschen Fehler durch, vor allem bei Folge- und Doppelverordnungen, weil die Praxissoftware den Verordnungsfall nicht zeigt.
2. **Analyse:** Unter sieben möglichen Einsatzfeldern liegt nur der Verordnungs-Check bei Nutzen und Machbarkeit oben.
3. **Lösung:** Ein System, das vor der Behandlung prüft, jeden Befund mit Fundstelle belegt und die Entscheidung bei der Rezeption lässt.
4. **Nachweis:** Zielwert 98 % richtige Ampeln gegen höchstens 85 % bei menschlicher Doppelkontrolle, gemessen an den Regelwerken. Erreicht: 96,6 % nach Einbau der Regeln in den Code, im Blindtest davor 83,1 %; keine übersehene rote Verordnung. Nach unseren Kriterien heißt das: bedingt bereit.
5. **Nutzen:** ab dem zweiten Jahr rund 4.300 € pro Jahr an Prüfzeit, etwa ein halber Minijob, der für Patienten und Telefon frei wird.

2 Was wir gelernt haben

Fehler finden war leicht, Fehlalarme senken war die Arbeit. Schon die erste Version erkannte alle acht eingebauten Fehler, meldete aber zwölf kritische Fehlalarme. Für die Akzeptanz ist ein Werkzeug, das zu oft Rot zeigt, genauso schlecht wie eines, das Fehler übersieht. Diese Einsicht hat unsere Erfolgskriterien geprägt: Neben der Trefferquote gibt es eine harte Grenze für Fehlalarme.

Regeln gehören in den Code. Das Sprachmodell hat Tage falsch gezählt, Prüfziffern im Kopf geprüft und einen Knie-Code der Wirbelsäule zugeordnet, jedes Mal mit plausibler Begründung. Bessere Anweisungen haben das nur gemildert, gelöst hat es erst Code. Das Muster hat sich bis zuletzt wiederholt, bei der Leitsymptomatik und beim Hinweis auf besonderen Verordnungsbedarf. Der Leitsatz „Was sich als Regel aufschreiben lässt, rechnet der Code“ ist das wichtigste Ergebnis dieser Arbeit, wichtiger als jede einzelne Verbesserung an den Anweisungen.

Die Field Study hat den Schwerpunkt verschoben. Unsere ersten vier Prüfer zielten auf die einzelne Verordnung: Pflichtangaben, Diagnose, Menge und Fristen. Schon eine erste Rückmeldung der Praxis deutete auf Folgeverordnungen, das Interview hat es beziffert: 90 % der Fehler. Damit wurde die Verordnungsfall-Prüfung zur obersten Priorität. Ohne das Gespräch hätten wir weiter an den übrigen 10 % optimiert. Auch der Business Case hat sich gedreht: Wir hatten mit dem Absetzungsrisiko gerechnet und haben eine Zeitfrage gefunden.

Zusammenführen braucht Kompatibilität. Beim Zusammenführen zweier Entwicklungsstände zeigte sich, dass ein anderes Embedding-Modell die gesamte Wissensbasis unbrauchbar macht. Seitdem halten wir

immer eine lauffähige Rückfallversion bereit und führen ein Änderungsprotokoll mit Anlass, Änderung und Test.

Die Evaluation hat den Leitsatz noch einmal bewiesen. Beim Zusammenführen war die Leitsymptomatik-Regel aus dem Code entfallen, und das Modell prüfte Mengen, obwohl die Summe als Fakt vorlag. Im Blindtest lagen 7 von 10 Fehlern genau dort. Mit fünf Regeln im Code stieg die Quote von 83 auf 97 %, ohne eine Zeile an den Anweisungen zu ändern.

Die Laufzeitumgebung gehört zur Architektur. Der Redaktionsdienst mit Namensmodell lief lokal, die Prüfung in der Cloud. Die Cloud erreicht ihn nicht, deshalb laufen dort nur die Regeln. Wer ein System baut, muss früh festlegen, wo es läuft.

Messen ehrlich halten. Wer Testfälle zum Nachbessern benutzt, kann mit ihnen nichts mehr beweisen. Unsere frühen zehn von zehn sind deshalb ausdrücklich keine formale Evaluation. Für die formale Messung haben wir Entwicklungs- und Evaluationsfälle vor dem ersten Lauf getrennt.

Teamarbeit unter Veränderung. Während des Projekts hat ein Teammitglied die Gruppe verlassen. Wir haben die Aufgaben auf drei Personen verteilt und eine vorher festgelegte Streichliste genutzt. Was zuerst wegfällt, war schon bekannt, deshalb mussten wir unter Zeitdruck nicht neu verhandeln. Nicht gestrichen wurden die harten Erfolgskriterien und der Datenschutz.

3 Vorgehen für künftige Umsetzungen

Aus dem Projekt leiten wir ein Vorgehen ab, das sich auf andere KI-Einführungen in kleinen Unternehmen übertragen lässt.

Nr.	Grundsatz	Was das konkret heißt
1	**Erst verstehen, dann bauen**	Field Study mit Zahlen und Einheiten, bevor die erste Zeile Code entsteht
2	**Klein anfangen**	ein Arbeitsschritt mit klarer Grenze statt einer „KI für alles“
3	**Kriterien vor dem Test**	Zielwert, harte Bedingungen und Referenzstandard schriftlich, bevor gemessen wird
4	**Testfälle trennen**	ein Set zum Nachbessern, ein Set nur zum Messen
5	**Regeln in Code, Sprache ins Modell**	bei jedem Fehler fragen: Ist das eine Regel? Dann gehört sie in den Code
6	**Der Mensch entscheidet**	das System empfiehlt und belegt, die Verantwortung bleibt im Unternehmen
7	**Recht an der Zweckbestimmung festmachen**	ändert sich der Zweck, wird die Einordnung neu geprüft
8	**Parallelbetrieb vor Umstellung**	erst messen, dann alte Kontrollen abbauen

4 Die Auswahl ist nicht statisch

Die getroffene Auswahl gilt für den heutigen Stand. Drei Entwicklungen werden sie verändern.

Elektronische Verordnung. Heilmittelverordnungen sollen künftig elektronisch über die Telematikinfrastruktur kommen. Dann liegen die Daten strukturiert vor, Formular, Foto und Texterkennung werden zur Übergangslösung, und der Eingabekanal ist neu zu bewerten.

Datenschutz im Echtbetrieb. Für echte Patientendaten ist ein Sprachmodell mit Datenhaltung oder Betrieb in der EU neu zu bewerten.

Modelle und Preise. Sprachmodelle werden schneller und günstiger. Weil die harte Logik im Code liegt und alle Prüfer dasselbe Ausgabeschema nutzen, lässt sich das Modell mit überschaubarem Aufwand tauschen. Jeder Tausch braucht aber einen neuen Lauf der Evaluation. Das ist kein theoretischer Fall: OpenAI führt gpt-4.1-mini inzwischen als veraltetes Modell und empfiehlt einen Nachfolger.

> **Nächste Bausteine**
>
> 1. Doppelverordnungs-Prüfung, die dieselbe Historie nutzt wie die Verordnungsfall-Prüfung. 2. Schnittstelle zur Praxissoftware, die die Eingabe von Hand ersetzt und die Historie von Anfang an füllt. 3. Die zentrale Terminvergabe als Weiche zwischen Verordnungs-Check für Kassenpatienten und Erstattungshinweis für Privatpatienten.

5 Fazit und Empfehlung

96,6 %	vorher	≈ 4.300 €
richtige Ampeln, Ziel 98 %, gegen höchstens 85 % bei menschlicher Doppelkontrolle	Fehler fallen vor der Behandlung auf, nicht erst bei der Abrechnung	pro Jahr ab dem zweiten Jahr, etwa ein halber Minijob an Prüfzeit

Wir empfehlen der Praxis, den Verordnungs-Check im Parallelbetrieb zu starten: sechs Wochen mitlaufen lassen, messen, dann entscheiden. Vorher setzen wir die beiden offenen Punkte aus Kapitel 5 um: die KBV-Liste als Tabelle im Code und die Verordnungsfall-Prüfung, denn dort entstehen laut Field Study 90 % der Fehler. Das System ist kein Hochrisiko-KI-System, der Datenschutz ist durch Technik eingebaut, und die Rezeption behält die Entscheidung. Sie gewinnt Zeit, die heute in der Verwaltung steckt und künftig den Patienten zugutekommt.